

长短期记忆 & 记忆评估

Yanxiang Ling

The slide features several decorative geometric shapes in a lighter shade of blue. These include a horizontal bar on the left, a vertical bar on the right, and a large rounded rectangle in the bottom right corner. There are also several smaller rectangular blocks arranged in a grid-like pattern at the bottom of the slide.

Why LLM agent needs Memory?

Role-playing



[Iron Man] My name is Iron Man, also known as Tony Stark. I am the founder of Stark Industries and a member of the Avengers. As one of the genius inventors and billionaire, I have created the most advanced armor in the world, which not only protects me but also gives me incredible strength and the ability to fly.




Open-world Game



Code Generation

```
</> Sort the numbers in ascending order.
def bubble_sort(arr):
    n = len(arr)
    # Traverse through all array elements
    for i in range(n):
        # Last i elements are already in place
        for j in range(0, n-i-1):
            # Traverse the array from 0 to n-i-1
            # Swap if the element found is greater
            # than the next element
            if arr[j] > arr[j+1]:
                arr[j], arr[j+1] = arr[j+1], arr[j]
    return arr
```




Social Simulation



I'm a compassionate physician specializing in cardiology, committed to improving patients' heart health and well-being.

I'm a skilled nurse dedicated to patient care, ensuring comfort and supporting health with empathy and expertise.


Environment



Recommendation



Personal Assistant



(Knowledge) According to the previous works, large language model based agents refer to artificial
(Context) The current topic is LLM-based agent. "It" refers to LLM-based agents in this conversation.

Finance

Yesterday, the financial market underwent significant fluctuations. Equity markets initially slumped as investors responded to weak corporate earnings reports and concerns over global economic growth prospects. Bond yields declined as investors sought safer assets. However, sentiment improved in the afternoon following better-than-expected economic data from a major economy, which boosted investor confidence. As a result, stock prices recovered, and the market closed with modest gains.

The yield on the 10-year Treasury note rose by 0.2 percentage points, reaching its highest level in two years. Investors sought safer assets, leading to increased demand for government bonds. Corporate bonds experienced a decline in interest, with their yields rising by 0.15 percentage points.

Medicine

David, a 38-year-old male with a history of allergies and sinus infections, has a family history of diabetes and hypertension. As a smoker of about one pack a day and an occasional drinker, his lifestyle choices may contribute to his health risks. After traveling to a tropical country where mosquito-borne illnesses are prevalent, he has experienced symptoms such as mild fatigue, headache, and muscle aches for the past week.

The patient's travel history and symptoms suggest dengue fever, a mosquito-transmitted illness.

For three days, I've had a fever ranging from 100.5°F to 102°F, a rash on my limbs, joint pain and swelling, especially in my hands, episodes of diarrhea, abdominal pain, and nausea, leading to a loss of appetite.

Memory for LLM Agents

• What is Memory?

- 狭义：同一任务内的历史交互信息
- 广义：
 - 同一任务内的历史交互信息
 - 跨多个任务的历史交互信息
 - 外部知识

01 同一任务内的历史交互信息

- Generative Agent：为实现特定目标而产生的历史行为
- MemoChat：基于单个对话会话的历史对话内容
- TiM：智能体完成任务后，让其自主生成多个思考过程，并将这些思考过程作为记忆
- Voyager：构建基于《我的世界》（Minecraft）的游戏智能体，其记忆中包含完成任务所需的初步基础动作可执行代码。

02 跨多个任务内的历史交互信息

- Reflexion：以语言形式从过往任务中提取经验，将这些经验应用于后续任务
- Synapse：专注于解决计算机控制类任务，记录成功案例
- ExpeL：智能体在环境中解决一系列复杂的交互任务，存储并整理已完成的轨迹，并为新任务召回相似的轨迹。在召回的轨迹中，对比成功案例与失败案例，以识别成功模式。。

03 外部知识

- ReAct：在推理过程中，若智能体缺乏相关信息，可利用维基百科 API 获取外部知识。
- GITM：《我的世界》中的智能体，决策中智能体可参考在线《我的世界》维基百科和攻略。

Memory for LLM Agents

• 智能体记忆 VS 大模型记忆

Memory in the Age of AI Agents

- 大模型记忆：直接干预模型内部状态的机制，比如长上下文架构改造、缓存重写、循环状态保持、注意力稀疏化、外置 KV 存储扩展等，其目标是扩展或重组底层模型的代表能力。通常不支持跨任务持久化、环境驱动适应或有意的记忆操作。
- 智能体记忆：为决策智能体提供一个可演化的外部记忆库。

• 智能体记忆 VS RAG

- 经典 RAG 主要为大模型提供对静态外部知识源的访问，旨在让生成以最新事实为据、缓解幻觉、提升知识密集型任务的准确率。
- 智能体记忆系统内嵌于智能体与环境的持续交互之中，不断将智能体自身行为与环境反馈产生的新信息纳入持久记忆库。

• 智能体记忆 VS 上下文工程

- 上下文工程管“窗口内的资源调度”，记忆管“跨时间的认知连续性”
- 二者在短期记忆处理上，存在压缩、组织、选择等重叠。

长短期记忆系统

长期与短期的划分标准：**信息来源**和**时间尺度**

短期记忆：容量受限，临时存储，主动控制。与当前任务高度相关的信息。



反思抽象

长期记忆：①过去事件、用户特定信息和外部环境状态的**事实记忆**；②长期积累形成的**经验记忆**。

- 短期记忆：用受限的上下文窗口模拟短期记忆的"有限容量 + 主动操纵"
- 长期记忆：用可演化的外部记忆库模拟长时记忆的"持久积累 + 按需检索"
- 短期向长期转换：用反思与抽象。

长短期记忆系统

记忆形成：在时刻 t ，智能体产生信息性产物 φ_t （工具输出、推理轨迹、部分计划、自我评估或环境反馈），将这些产物选择性地转化为候选记忆，提取具有潜在未来效用的信息，而非逐字存储全部交互历史。【**确定记忆内容，设计记忆存储结构**】

记忆检索：构造任务感知的查询，检索记忆库，返回相关记忆内容 m_t ，并将其格式化为大模型策略可直接使用的形式，例如文本片段序列或结构化摘要。【**调用与任务最相关的记忆内容**】

记忆进化：将记忆候选整合进现有记忆库，可执行冗余条目合并、冲突消解、低价值信息丢弃，或为了高效检索而重组记忆结构。【**生成新的、高阶的记忆**】

长短期记忆系统

记忆形成：在时刻 t ，智能体产生信息性产物 ϕ_t （工具输出、推理轨迹、部分计划、自我评估或环境反馈），将这些产物选择性地转化为候选记忆，提取具有潜在未来效用的信息，而非逐字存储全部交互历史。

■ TiM

- 从原始信息中提取实体间的关系，并将其存储在结构化数据库中；写入数据库时，会将相似内容归为同一组。

■ MemoChat

- 智能体会对每个对话片段进行总结，提炼其中的核心讨论主题，并将这些主题作为索引，用于后续记忆条目的检索。

长短期记忆系统

记忆检索：构造任务感知的查询，检索记忆库，返回相关记忆内容 m_t ，并将其格式化为大模型策略可直接使用的形式，例如文本片段序列或结构化摘要。

■ ChatDB

- 通过 **SQL 语句**实现，智能体会提前生成一系列 “记忆链”，并基于这些链条生成 SQL 语句，进而从数据库中检索所需记忆。

■ MPC

- 从记忆池中检索相关记忆，通过 “**思维链**” 示例，帮助智能体学会忽略无关记忆。

■ Expel

- 将向量库作为记忆池，检索并获取与当前任务相似度最高的前 K 条成功轨迹。

长短期记忆系统

记忆进化： 将记忆候选整合进现有记忆库，可执行冗余条目合并、冲突消解、低价值信息丢弃，或为了高效检索而重组记忆结构。

■ MemoryBank

- 将对话内容提炼为**高级摘要**，类似人类回忆过往经历时聚焦关键信息的方式；通过长期交互，智能体会持续评估并完善自身知识体系，生成关于用户性格特质的日常洞察。

- **反思**生成更高级别记忆，**合并**冗余记忆条目，**遗忘**不重要的早期记忆。

TiM: Think in Memory

受人类记忆形成机制的启发，提出了一种基于“回忆-反思”双阶段过程的长期记忆框架。该框架使LLM能够像人类一样，通过**主动回忆历史信息并进行深度思考**，将**重要信息编码到长期记忆中**，从而在多轮交互中保持连贯性和个性化。

- Recalling
 - 从外部记忆存储中检索与当前上下文相关的历史信息
- Post-Thinking
 - 对检索到的记忆和生成的回复进行深度加工和整合，形成更高层次的记忆
- 记忆更新
 - 通过时间衰减和相关性评估记忆，进行插入、遗忘、合并操作




Figure 2: The overview of TiM framework. LLMs firstly recall history and give response for the question. Then new thoughts can be generated via the post-thinking step. These thoughts are saved as the memory to avoid repeated reasoning on the history.

SCM: Self-Controlled Memory

把历史信息存储到记忆流中，并由一个"记忆控制器"动态决定激活哪些长期记忆、如何将其融入当前模型输入，从而生成精确且连贯的响应。

- 记忆流
 - 统一存放历史信息。
- 记忆控制器
 - 为智能体同时提供长期记忆 (archived memory) 与短期记忆 (flash memory)，并决定应从归档记忆中激活哪些记忆、如何把它们并入模型输入。




Figure 2: The workflow of our proposed Self-Controlled Memory(SCM) from the six explicit steps of one iteration with new observation #T. These steps are: (1) Observation; (2) Memory Activation; (3) Memory Retrieval; (4) Memory Reorganization; (5) Input Fusion; (6) Response Generation.

MemGPT

将LLM比作CPU，将上下文窗口比作有限的RAM。借鉴操作系统中虚拟内存的分页机制，MemGPT通过函数调用在上下文和外部存储之间移动数据，使LLM能够处理远超上下文窗口的记忆信息。

- 主上下文 (Prompt Tokens)
 - working context: 存储关键事实、用户偏好、角色设定等高频访问信息
 - FIFO queue: 用户消息、Agent 回复、系统消息
- 外部归档存储
 - 存储大量历史信息
- Queue Manager
 - 消息追加、溢出控制
- Function Executor
 - 执行函数





Figure 3. In MemGPT, a fixed-context LLM processor is augmented with a hierarchy of its own memory. The LLM's prompt tokens (inputs), or *main context*, consist of the queue. The LLM completion tokens (outputs) are interpreted as function calls by move data between main context and *external context* (the archival and recall storage). The LLM follow-up LLM inference to chain function calls together by generating a special key in its output; function chaining is what allows MemGPT to perform multi-step retrieval.




Function: LLM 输出的结构化指令/工具调用。

ChatDB

将数据库作为LLM的符号记忆（Symbolic Memory），通过自然语言到SQL的转换，使LLM能够利用关系数据库进行精确的结构化知识存储和查询。核心思想是结合LLM的语义理解能力和数据库的符号推理能力，实现优势互补。

- 记忆读写：
 - 写: 将对话中的结构化信息（如事实、关系）存入数据库
 - 读: 通过SQL查询检索精确的符号信息
- 多记忆类型支持: 支持关系型数据库中的表、记录、关系等结构化存储
- 链式SQL生成: 对于复杂查询，支持多步SQL的链式生成和执行



MIRIX: Multi-Agent Memory

用六种结构化的记忆类型 + 多智能体框架，动态控制和协调记忆的更新与检索，使智能体能大规模持久化、推理并准确检索多样化的长期用户数据。

- 多种记忆
- 多智能体组成的记忆管理模块
 - 元记忆管理器：中央路由器和协调者
 - 6类记忆管理器：每个记忆组件配备一个专用管理智能体
 - 对话智能体：用户的自然语言交互接口
- 主动检索
 - embedding_match（向量相似度）、bm25_match（关键词匹配）、string_match（字符串匹配）等多种检索策略，Agent 可根据查询特点自主选择最合适的方法。




Figure 1: The six memory components of MIRIX, each providing specialized functionality.

RMM: Reflective Memory Management

提出反思式记忆管理 (Reflective Memory Management, RMM) , 融合前向反思 (Prospective) 与后向反思 (Retrospective) 。




Figure 2: Illustration of *Prospective Reflection*. After each session, the agent decomposes and summarizes the session into specific topics. These newly generated memories are compared with existing memories in the memory bank. Relevant memories are merged, while others are directly added. Prospective reflection ensures efficient organization of personal knowledge for future retrieval.





Figure 3: Illustration of *Retrospective Reflection*. The Retriever fetches Top-K memory entries from the memory bank, which are refined by the learnable Reranker to select the Top-M most relevant entries. These entries are passed to the LLM along with the query to generate the final response. The LLM assigns binary citation scores (+1 for useful and -1 for not useful) to the retrieved memory entries based on their utility in the response. These scores are used as reward signals to update the reranker via an RL update, adapting the selection of relevant memory over time.

- 前向反思
 - 跨多个粒度 (utterance、turn、session) 动态摘要交互内容, 构建个性化记忆库。
- 后向反思
 - 基于 LLM 引用的证据, 以在线强化学习方式迭代精化检索过程, 使检索能适应不同对话语境与用户模式。

PREMem: Pre-storage Reasoning for Episodic Memory

提出预存储推理（pre-storage reasoning），在记忆写入时即完成跨会话的信息综合和关系建立，从而减轻推理时的计算负担，同时创建更丰富的记忆表征。




- 记忆构建
 - 将原始对话会话提取为结构化的记忆片段，并分为三类：
 - 事实记忆：状态、属性、拥有物、关系的客观事实
 - 经历记忆：经历过的具体事件、行动、互动
 - 主观记忆：偏好、观点、信念、目标、计划

Figure 1: **PREMem** architecture divided into *Memory Construction* phase (comprising Step 1: Episodic Memory Extraction and Step 2: Pre-Storage Memory Reasoning) and *Inference* phase.

PREMem: Pre-storage Reasoning for Episodic Memory

提出预存储推理（pre-storage reasoning），在记忆写入时即完成跨会话的信息综合和关系建立，从而减轻推理时的计算负担，同时创建更丰富的记忆表征。




- 存储前记忆推理
 - 聚类：对每轮会话的记忆片段做嵌入，自动确定最优聚类数，形成语义簇
 - 记忆池，保存之前会话中尚未找到语义匹配的簇
 - 计算新簇与持久池中的旧簇的余弦相似度，若超过阈值 $\theta=0.6$ ，则建立链接对
- 链接对推理：让 LLM 分析两个簇中的记忆片段，生成推理记忆片段
 - 扩展、积累、细化、转变、连接

Figure 1: **PREMem** architecture divided into *Memory Construction* phase (comprising Step 1: Episodic Memory Extraction and Step 2: Pre-Storage Memory Reasoning) and *Inference* phase.

Prompt Compression

引入"问题感知"的压缩策略，根据具体问题动态调整压缩过程，并通过文档重排序和子序列恢复等技术，增强模型对关键信息的捕获能力。



(a) Performance v.s. Document Number

- 文档重排序：将最相关的文档片段置于prompt的前部
- 动态压缩比：根据文档与问题的相关度分配不同的压缩比例





Figure 2: Framework of LongLLMLingua. Gray *Italic* content: As in LLMingua.

StructMem: Structured Memory

一个以"**基于时序的、关系性的事件**"为基本记忆单元，并通过"**双视角提取**（事件级绑定）"和"**周期性语义整合**（跨事件连接）"构建的**分层记忆框架**，能够在提升长程时序推理和多跳问答性能的同时，显著降低计算开销（token使用、API 调用、运行时间），从而优于现有的扁平记忆和图记忆范式。



- **事件级绑定：**双视角提取 + 时间戳绑定，将每一轮对话打包成一个完整「事件小包」存在缓存里。
- **跨事件整合：**批量挖掘跨时间隐藏关联，增强推理

MemSkill: Memory Skills

记忆操作本身是固定的、由人事先定义的，系统能学习的仅仅是在预定义操作之间做选择，但操作集合本身无法更新。


不同任务领域需要完全不同的记忆行为，手工定义的操作集无法覆盖所有这些场景

能否将记忆操作本身提升为一个可学习、可进化的“技能”，系统不仅学习“何时使用哪种记忆操作”，还能学习“记忆操作本身该如何改进和扩展”？

记忆技能：一种结构化、可复用的知识单元，包含使用时机、操作方法和约束条件。


MemSkill: Memory Skills

MemSkill: 将记忆操作建模为一个可进化的技能库 $S = \{s_1, s_2, \dots, s_k\}$, 每个技能是包含描述、操作规范和约束条件的结构化文本。系统通过“学习使用技能”和“进化技能”两个交替过程进行的过程实现自我进化



MemSkill: Memory Skills

- **记忆库 (Memory Bank)** : 每个trace对应一个记忆库
- **技能库 (Skill Bank)** : 所有trace共享, 可复用的记忆技能



Skill

- **description**: 技能嵌入和检索
- **content**: When to use (使用时机)、How to apply (操作方法) 和 Constraints (约束条件)
- **INSERT**: 新增一条全新记忆
- **UPDATE**: 修改已经存过的旧信息
- **DELETE**: 删掉过时、矛盾的旧记忆
- **SKIP**: 这段内容没用, 啥也不存

长短期记忆系统

记忆形成：在时刻 t ，智能体产生信息性产物 φ_t （工具输出、推理轨迹、部分计划、自我评估或环境反馈），将这些产物选择性地转化为候选记忆，提取具有潜在未来效用的信息，而非逐字存储全部交互历史。【**确定记忆内容，设计记忆存储结构**】

记忆检索：构造任务感知的查询，检索记忆库，返回相关记忆内容 m_t ，并将其格式化为大模型策略可直接使用的形式，例如文本片段序列或结构化摘要。【**调用与任务最相关的记忆内容**】

记忆进化：将记忆候选整合进现有记忆库，可执行冗余条目合并、冲突消解、低价值信息丢弃，或为了高效检索而重组记忆结构。【**生成新的、高阶的记忆**】

记忆系统评估

直接评估：将记忆模块作为独立组件，直接测量其读写能力与内容质量

- **主观评估：**基于人工标注判断记忆内容的质量
 - 一致性 (Coherence) —— 记忆是否与当前上下文相关
 - 合理性 (Rationality) —— 记忆内容是否符合常识
- **客观评估：**基于数值指标进行自动化的量化比较
 - 结果正确性 (Correctness) —— Accuracy
 - 引用准确性 (Accuracy) —— F1-score
 - 效率 (Time & Hardware Cost) —— 延迟、显存

间接评估：通过端到端 Agent 下游任务的完成效果来反推记忆模块的有效性

- 对话任务 —— 一致性、参与度
- 多源问答 —— 跨源信息整合能力
- 长上下文应用 —— 超长文本中的信息定位与利用

记忆系统评估

客观评估指标：有效性

结果正确性关注"最终答案是否正确"，而引用准确性关注"中间推理依据是否恰当"。

指标	计算方法	评估目标
结果正确性 (Result Correctness)	Accuracy	Agent 能否基于记忆正确回答预设问题
引用准确性 (Reference Accuracy)	F1	检索到的记忆内容是否包含支撑答案的关键信息

客观评估指标：检索质量

指标	说明	适用场景
Hit Rate	正确文档是否出现在检索结果中	粗粒度检索有效性
MRR	首个正确结果的倒数排名	关注排序质量
NDCG@K	归一化折损累积增益	综合评估排序质量与相关性
Recall@K	前 K 个结果中相关文档的比例	关注查全率

记忆系统评估

客观评估指标：生成质量

结果正确性关注"最终答案是否正确"，而引用准确性关注"中间推理依据是否恰当"。

指标	说明
上下文相关性 (Context Relevance)	检索内容与查询的相关程度，减少无关信息引入的处理开销
答案忠实度 (Answer Faithfulness)	生成答案是否忠实于检索到的上下文，避免幻觉
答案相关性 (Answer Relevance)	生成答案与原始问题的匹配程度

客观评估指标：效率

指标	计算方法	说明
时间开销 (Time Cost)	$\Delta t = (1/M) \sum (t_{end} - t_{start})$	包含记忆写入/管理（适配时间）与记忆读取（推理延迟）
计算开销 (Computation Overhead)	峰值 GPU 显存分配	评估硬件资源消耗

记忆系统评估

维度	分类	评估重点
记忆形式	Token 级记忆	可读性、可编辑性、检索精度
	参数级记忆	知识内化程度、灾难性遗忘
	隐式记忆	表示质量、隐私保护、压缩效率
记忆功能	工作记忆	短期信息保持、上下文压缩效率
	情景记忆	事件序列准确性、时序一致性
	语义记忆	知识覆盖度、概念关联准确性
记忆内容	事实记忆 (Factual)	客观知识召回准确率
	经验记忆 (Experiential)	行为策略的有效性
时间尺度	任务内 (Inside-trial)	单轮/多轮交互中的信息保持
	跨任务 (Cross-trial)	长期知识积累与迁移

记忆系统评估

问答任务

Benchmark	特点	适用评估
HotpotQA (Yang et al., 2018)	多跳推理问答	多源信息整合、长上下文 QA
2WikiMQA (Ho et al., 2020)	基于 Wikipedia 的多跳问答	跨文档信息检索
MuSiQue (Trivedi et al., 2022)	通过单跳问题组合构造多跳问题	复杂推理链构建
Natural Questions (NQ) (Kwiatkowski et al., 2019)	真实用户查询的单跳事实问答	单跳事实召回

对话任务

Benchmark	特点	适用评估
LoCoMo (Maharana et al., 2024)	真实对话中的长程记忆	会话记忆、persona 一致性
LongMemEval (Wu et al., 2025a)	交互式长程记忆评估	长程记忆保持
PerLTQA (Du et al., 2024)	个性化长期记忆问答	个人化事实记忆
MemoryBank (Zhong et al., 2024)	用户记忆更新	动态记忆更新
LOCCO (Jia et al., 2025)	时序对话	时间敏感的记忆
DialSim (Zheng et al., 2025b)	真实多轮对话理解	多轮对话一致性

记忆系统评估

功能智能体任务

Benchmark	特点	适用评估
MemBench (Tan et al., 2025a)	交互式场景	Agent 综合记忆能力
MemoryAgentBench (Hu et al., 2025c)	多轮交互	Agent 记忆系统
WebChoreArena (Miyai et al., 2025)	真实网页浏览	复杂任务中的经验记忆
MT-Mind2Web (Deng et al., 2024)	对话式网页导航	多轮交互中的经验积累
PersonaMem (Jiang et al., 2025a)	动态用户画像	persona 记忆
MPR (Zhang et al., 2025u)	用户个性化	个性化推荐记忆
PrefEval (Zhao et al., 2025d)	个人偏好	偏好学习
StoryBench (Wan and Ma, 2025)	交互式小说游戏	叙事一致性
Madial-Bench (He et al., 2025)	记忆召回	记忆检索准确性

记忆系统评估

代码生成与推理任务

Benchmark	特点	适用评估
SWE-bench Verified (Jimenez et al., 2024)	真实 GitHub Issue 解决	代码 Agent 的经验记忆
GAIA (Mialon et al., 2023)	通用 AI 助手评估	复杂问题求解
XBench (Chen et al., 2025b)	跨领域评估	Agent 综合能力
BrowseComp (Wei et al., 2025b)	浏览竞争	信息检索能力
BRIGHT (Su et al., 2024)	推理密集型检索	RAG+推理
OlympiadBench (He et al., 2024)	奥林匹克级别数学竞赛	深度推理

深度研究与报告生成任务

Benchmark	特点
Deep Research	博士级别跨领域研究任务
WildSeek (Chen et al., 2025)	真实信息搜寻场景
Review-5k	ICLR 2024 同行评审数据集
SolutionBench (Guan et al., 2025)	工程领域问题求解

记忆系统评估

1. 明确评估目标 —— "评什么？"

- 记忆形式：评估的是什么格式的记忆？
- 功能维度：关注的是短期还是长期记忆？
- 应用场景：面向问答、对话、代码生成还是复杂推理？

2. 选择评估策略 —— "怎么评？"

- 若目标是比较不同记忆机制的本质优劣 → 采用直接评估
- 若目标是验证记忆模块在完整系统中的实际贡献 → 采用间接评估
- 若缺乏客观真值或需要理解性分析 → 采用主观评估
- 若追求可复现、可比较的量化结果 → 采用客观评估

3. 设计/选择评估指标 —— "用什么量？"

4. 构建/选择 Benchmark —— "在什么上评？"

参考文献

二、记忆形成

1. TiM

Lei Liu, Xiaoyan Yang, Yue Shen, Binbin Hu, Zhiqiang Zhang, Jinjie Gu, and Guannan Zhang. Think-in-Memory: Recalling and Post-thinking Enable LLMs with Long-term Memory. arXiv preprint arXiv:2311.08719, 2023.

2. SCM

Xinnian Liang, Bing Wang, Hui Huang, Shuangzhi Wu, Peihao Wu, Lu Lu, Zejun Ma, and Zhoujun Li. Unleashing Infinite-Length Input Capacity for Large-scale Language Models with Self-Controlled Memory System. arXiv preprint arXiv:2304.13343, 2023.

3. MemGPT

Charles Packer, Vivian Fang, Shishir G. Patil, Kevin Lin, Sarah Wooders, and Joseph E. Gonzalez. MemGPT: Towards LLMs as Operating Systems. arXiv preprint arXiv:2310.08560, 2023.

4. MemoChat

Junru Lu, Siyu An, Mingbao Lin, Gabriele Pergola, Yulan He, Di Yin, Xing Sun, and Yunsheng Wu. MemoChat: Tuning LLMs to Use Memos for Consistent Long-Range Open-Domain Conversation. arXiv preprint arXiv:2308.08239, 2023.

参考文献

三、记忆检索

1. ChatDB

Chenxu Hu, Jie Fu, Chenzhuang Du, Simian Luo, Junbo Zhao, and Hang Zhao. ChatDB: Augmenting LLMs with Databases as Their Symbolic Memory. arXiv preprint arXiv:2306.03901, 2023.

2. ExpeL

Andrew Zhao, Daniel Huang, Quentin Xu, Matthieu Lin, Yong-Jin Liu, and Gao Huang. ExpeL: LLM Agents Are Experiential Learners. arXiv preprint arXiv:2308.10144, 2023.

3. MIRIX

Yu Wang and Xi Chen. MIRIX: Multi-Agent Memory System for LLM-Based Agents. arXiv preprint arXiv:2507.07957, 2025.

4. Mem- α

Yu Wang, Ryuichi Takanobu, Zhiqi Liang, Yuzhen Mao, Yuanzhe Hu, Julian J. McAuley, and Xiaojian Wu. Mem- α : Learning Memory Construction via Reinforcement Learning. CoRR, abs/2509.25911, 2025.

参考文献

四、记忆进化

1.RMM

Zhen Tan, Jun Yan, I-Hung Hsu, Rujun Han, Zifeng Wang, Long T. Le, Yiwen Song, Yanfei Chen, Hamid Palangi, George Lee, Anand Rajan Iyer, Tianlong Chen, Huan Liu, Chen-Yu Lee, and Tomas Pfister. In Prospect and Retrospect: Reflective Memory Management for Long-term Personalized Dialogue Agents. In Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), ACL 2025, Vienna, Austria, pages 8416–8439, 2025.

2. PREMem

Sangyeop Kim, Yohan Lee, Sanghwa Kim, Hyunjong Kim, and Sungzoon Cho. Pre-storage Reasoning for Episodic Memory: Shifting Inference Burden to Memory for Personalized Dialogue. CoRR, abs/2509.10852, 2025.

3. Zep

Preston Rasmussen, Pavlo Paliychuk, Travis Beauvais, Jack Ryan, and Daniel Chalef. Zep: A Temporal Knowledge Graph Architecture for Agent Memory. CoRR, abs/2501.13956, 2025.

4. MemoryBank

Wanjun Zhong, Lianghong Guo, Qiqi Gao, and Yanlin Wang. MemoryBank: Enhancing Large Language Models with Long-Term Memory. arXiv preprint arXiv:2305.10250, 2023.

参考文献

五、短期记忆

1. LLMingua

Huiqiang Jiang, Qianhui Wu, Chin-Yew Lin, Yuqing Yang, and Lili Qiu. LLMingua: Compressing Prompts for Accelerated Inference of Large Language Models. In Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing (EMNLP 2023), Singapore, pages 13358–13376, 2023.

2. LongLLMingua

Huiqiang Jiang, Qianhui Wu, Xufang Luo, Dongsheng Li, Chin-Yew Lin, Yuqing Yang, and Lili Qiu. LongLLMingua: Accelerating and Enhancing LLMs in Long Context Scenarios via Prompt Compression. In Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), ACL 2024, Bangkok, Thailand, pages 1658–1677, 2024.

3. ICAE

Tao Ge, Jing Hu, Lei Wang, Xun Wang, Si-Qing Chen, and Furu Wei. In-context Autoencoder for Context Compression in a Large Language Model. In The Twelfth International Conference on Learning Representations (ICLR 2024), Vienna, Austria, 2024.

参考文献

六、长期记忆

1. Reflexion

Noah Shinn, Federico Cassano, Ashwin Gopinath, Karthik R. Narasimhan, and Shunyu Yao. Reflexion: Language Agents with Verbal Reinforcement Learning. In Thirty-seventh Conference on Neural Information Processing Systems (NeurIPS), 2023.

2. Voyager

Guanzhi Wang, Yuqi Xie, Yunfan Jiang, Ajay Mandlekar, Chaowei Xiao, Yuke Zhu, Linxi Fan, and Anima Anandkumar. Voyager: An Open-Ended Embodied Agent with Large Language Models. arXiv preprint arXiv:2305.16291, 2023.

3. Memp

Runnan Fang, Yuan Liang, Xiaobin Wang, Jialong Wu, Shuofei Qiao, Pengjun Xie, Fei Huang, Huajun Chen, and Ningyu Zhang. Memp: Exploring Agent Procedural Memory. arXiv:2508.06433, 2025.

4. LARP

Ming Yan, Ruihao Li, Hao Zhang, Hao Wang, Zhilan Yang, and Ji Yan. LARP: Language-Agent Role Play for Open-World Games. arXiv:2312.17653, 2023.